



MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL
MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Formativa 2

Modelamiento Predictivo (práctica)

Notebook grupal · 0 % (formativa)

Título del proyecto:	Análisis Estadístico de la Calidad del Aire en Santiago: Inequidad Ambiental y Episodios Críticos de Material Particulado
Integrantes:	Rodrigo Chinchón Ayala; Sergio Fernández Almonacid; Pablo Villalobos González
Dataset:	Red SINCA/MMA, Santiago RM; escala estación-día 2022-2025; 16.071 observaciones, 11 estaciones y 36 variables
Docente:	Jean Paul Maidana González
Fecha:	05/07/2026
Repositorio GitHub:	https://github.com/Rfcha/abp_estadistica

Información de la evaluación

Fase del proyecto:	Fase 3: Desarrollo del proyecto
Modalidad:	Grupal
Ponderación:	0 % (formativa)
Entregable:	Formativa2_Modelamiento_Predictivo_Grupo3.ipynb ejecutable, con síntesis final en Markdown.
Resultado de aprendizaje:	RA3: evaluar modelos de regresión para problemas de predicción y clasificación en contextos de negocio o ingeniería.
Indicadores:	ID3.1, ID3.2
Prerrequisito:	Sumativas 1 y 2 completadas (usarán sus resultados).

Conexión con evaluaciones anteriores

Esta práctica formativa **no es independiente**: requiere el uso explícito de los resultados de S1 y S2 (selección de variables, tratamiento de outliers, correlaciones validadas y parámetros robustos), y prepara directamente la Evaluación Sumativa 3.


Preparación de datos para modelamiento

El dataset utilizado corresponde a la base SINCA/MMA trabajada en las evaluaciones anteriores, agregada a escala estación-día para Santiago RM durante el período 2022-2025. La base fue caracterizada en la Formativa 1 con 16.071 observaciones, 11 estaciones de monitoreo y 36 variables ambientales, meteorológicas, territoriales y socioambientales.

La variable de interés ambiental es MP2.5, dado que en el análisis exploratorio e inferencial previo presentó una media aproximada de 24,94 $\mu\text{g}/\text{m}^3$, alta variabilidad relativa y asimetría positiva. Además, se identificaron registros sobre la norma diaria o en categorías superiores, relevantes para decisiones preventivas de salud pública.

A partir de la retroalimentación recibida en la Formativa 1, se incorporan dos elementos de cobertura: una matriz de correlación entre MP2.5, MP10, O3 y temperatura; y un intervalo de confianza Wilson para la proporción de registros con episodio crítico o superación relevante. Ambos cálculos quedan implementados en el notebook y se usan como soporte para justificar la selección de variables predictoras.

Elemento integrado	Uso en el modelamiento
Matriz de correlación MP2.5, MP10, O3 y temperatura	Permite observar relaciones lineales entre contaminantes y variables meteorológicas, respaldando la selección de predictores.
IC Wilson para proporción de episodios críticos	Cuantifica la incertidumbre de la proporción observada de registros críticos y conecta directamente con la variable objetivo binaria.
Hallazgo de inequidad ambiental Q1 vs Q5	Justifica considerar quintil socioeconómico o variables socioambientales como predictores.
Diferencia territorial Poniente vs Oriente	Justifica incorporar zona, sector o territorio como variable explicativa.



Matriz de correlación Pearson:					IC Wilson 95% para proporción de episodios críticos	
	mp25	mp10	o3	temperatura	Eventos críticos: 64 de 5,000	
mp25	1.000	0.672	-0.013	0.326	Proporción observada: 0.0128	
mp10	0.672	1.000	-0.001	0.222	IC95 Wilson: [0.0100, 0.0163]	
o3	-0.013	-0.001	1.000	0.453		
temperatura	0.326	0.222	0.453	1.000		

La variable objetivo se define como episodio_critico_mp25, con valor 1 para registros día-estación con episodio crítico o superación relevante asociada a MP2.5 y valor 0 para registros sin episodio crítico. Si existe una categoría de calidad del aire, se utiliza dicha clasificación; si no está disponible, se aplica un umbral operacional sobre MP2.5 como criterio reproducible.

La preparación de datos considera eliminación de duplicados exactos, inspección de valores faltantes, imputación simple mediante mediana para variables numéricas y moda para variables categóricas, partición train/test 70/30 y estandarización de variables numéricas dentro de un pipeline para evitar fuga de información desde el conjunto de prueba.

Modelo de regresión logística

El problema se formula como una clasificación binaria, por lo que se ajusta un modelo de regresión logística. El modelo estima la probabilidad de que un registro día-estación pertenezca a la clase 1, es decir, que presente episodio crítico o superación relevante de MP2.5.

La selección se restringe a 3-5 predictores, conforme a la instrucción de la evaluación, priorizando variables con fundamento estadístico, ambiental y territorial. Se evita usar MP2.5 directamente como predictor cuando este contaminante se utiliza para construir la variable objetivo, con el fin de prevenir fuga de información.

Predictor candidato	Justificación según S1/S2 y contexto
MP10	Contaminante asociado al material particulado; su correlación con MP2.5 se evalúa en la matriz solicitada.
Temperatura	Variable meteorológica vinculada a estacionalidad y dispersión de contaminantes.
Inversión térmica o variable equivalente	Condición físico-ambiental asociada a episodios invernales y acumulación de contaminación.
Quintil socioeconómico	Responde al hallazgo de inequidad ambiental entre Q1 y Q5 observado en la etapa inferencial.
Zona geográfica o sector	Permite capturar diferencias territoriales, especialmente la comparación Poniente/Oriente.

Logit Regression Results						
=====						
Dep. Variable:	episodio_critico_mp25	No. Observations:	3500			
Model:	Logit	Df Residuals:	3488			
Method:	MLE	Df Model:	11			
Date:	Tue, 07 Jul 2026	Pseudo R-squ.:	0.3913			
Time:	21:50:28	Log-Likelihood:	-146.48			
converged:	True	LL-Null:	-240.63			
Covariance Type:	nonrobust	LLR p-value:	1.971e-34			
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	-6.6828	0.737	-9.063	0.000	-8.128	-5.238
mp10	1.8181	0.234	7.777	0.000	1.360	2.276
temperatura	-0.2448	0.285	-0.860	0.390	-0.803	0.313
inversion_termica	1.0820	0.331	3.267	0.001	0.433	1.731
quintil_socioeconomico_Q2	-0.6005	0.436	-1.376	0.169	-1.456	0.255
quintil_socioeconomico_Q3	-0.7894	0.501	-1.576	0.115	-1.771	0.192
quintil_socioeconomico_Q4	-1.2278	0.589	-2.084	0.037	-2.383	-0.073
quintil_socioeconomico_Q5	-1.9937	1.050	-1.898	0.058	-4.052	0.065
zona_geografica_Norte	0.4428	0.699	0.634	0.526	-0.927	1.812
zona_geografica_Oriente	-0.4663	1.170	-0.399	0.690	-2.759	1.827
zona_geografica_Poniente	0.6248	0.616	1.014	0.310	-0.582	1.832
zona_geografica_Sur	0.4520	0.656	0.689	0.491	-0.833	1.737
=====						

El modelo se implementa mediante statsmodels para obtener resumen estadístico, coeficientes, p-valores e intervalos, y mediante scikit-learn para el flujo predictivo. Los coeficientes se interpretan en log-odds y se transforman a odds ratios para facilitar su lectura: un odds ratio mayor que 1 indica aumento en las chances del evento crítico, mientras que un odds ratio menor que 1 indica disminución relativa.

El diagnóstico básico de multicolinealidad se realiza mediante VIF. Como criterio operativo, valores inferiores a 5 se consideran usualmente aceptables, mientras que valores superiores a 10 sugieren multicolinealidad relevante. En caso de detectar problemas, el notebook los documenta y permite revisar la selección de predictores antes de la Sumativa 3.

Evaluación de desempeño predictivo

El desempeño predictivo se evalúa sobre el conjunto de prueba, no utilizado en el ajuste de los parámetros. Se genera la probabilidad estimada de episodio crítico y, con un umbral inicial de 0,50, se clasifican los registros en críticos y no críticos.


Métrica	Interpretación en el problema ambiental
Accuracy	Proporción total de clasificaciones correctas; debe interpretarse con cuidado si los episodios críticos son minoritarios.
Precision	Proporción de alertas predichas como críticas que efectivamente fueron críticas.
Recall	Proporción de episodios críticos reales detectados por el modelo; es clave para alerta temprana.
F1-score	Balance entre precision y recall, útil ante desbalance de clases.
AUC	Capacidad global del modelo para ordenar registros críticos por encima de no críticos a distintos umbrales.

valor	
accuracy	0.8460
precision	0.0691
recall	0.8947
f1_score	0.1283
auc	0.9392

Reporte de clasificación:				
	precision	recall	f1-score	support
0	1.00	0.85	0.92	1481
1	0.07	0.89	0.13	19
accuracy			0.85	1500
macro avg	0.53	0.87	0.52	1500
weighted avg	0.99	0.85	0.91	1500

La matriz de confusión permite distinguir verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos. En este caso, los falsos negativos son especialmente relevantes, porque corresponden a episodios críticos que el modelo no detecta y que podrían afectar decisiones sanitarias o preventivas.

La curva ROC y el AUC complementan la evaluación al mostrar el desempeño del clasificador en distintos umbrales. Un AUC cercano a 0,5 sugiere desempeño similar al azar; valores sobre 0,7 se interpretan como desempeño aceptable, sobre 0,8 como bueno y sobre 0,9 como excelente. La interpretación final debe priorizar no solo la exactitud global, sino la utilidad del modelo para anticipar episodios críticos en territorios vulnerables.




Síntesis y reflexión

La Formativa 2 transforma los hallazgos descriptivos e inferenciales previos en un flujo de modelamiento predictivo. Desde S1 se integran la distribución de MP2.5, la presencia de registros sobre norma, la diferencia territorial y la evidencia preliminar de inequidad ambiental entre quintiles socioeconómicos. Desde S2 se incorpora la lógica de validación mediante remuestreo, correlaciones estables y parámetros robustos, priorizando predictores con respaldo estadístico y sentido ambiental.

La regresión logística es pertinente porque la variable objetivo se define como binaria: presencia o ausencia de episodio crítico o superación relevante de MP2.5. La selección de 3-5 predictores permite mantener parsimonia e interpretabilidad, al mismo tiempo que conecta el modelo con contaminantes, meteorología, territorio y vulnerabilidad socioeconómica.

La evaluación mediante matriz de confusión, accuracy, precision, recall, F1-score, ROC y AUC permite analizar el desempeño de forma integral. Para este problema, recall y F1-score adquieren especial importancia, porque no detectar episodios críticos puede tener consecuencias sanitarias y ambientales mayores que emitir una alerta preventiva adicional.

Como mejoras para la Sumativa 3, se propone comparar distintos umbrales de clasificación, evaluar modelos alternativos, incorporar validación cruzada, analizar el desbalance de clases, robustecer la comparación territorial Poniente/Oriente y documentar de forma más precisa la estabilidad de predictores mediante remuestreo. La base metodológica queda preparada para avanzar hacia un modelo predictivo integrado y reproducible.



Mejoras metodológicas recomendadas

Interpretación ambiental de los Odds Ratios

Los odds ratios deben interpretarse considerando el contexto ambiental. Un odds ratio mayor que 1 indica un incremento relativo en la probabilidad de ocurrencia de episodios críticos de MP2.5, mientras que un valor menor que 1 representa un efecto protector. Estos resultados son coherentes con las correlaciones observadas en las evaluaciones previas (S1 y S2), reforzando la pertinencia de los predictores seleccionados.

Limitaciones del modelo

- La regresión logística modela relaciones lineales en el logit.
- No incorpora explícitamente dependencia temporal.
- El posible desbalance de clases puede afectar algunas métricas.
- Variables meteorológicas adicionales podrían mejorar la capacidad predictiva.

Trabajos futuros

Se recomienda evaluar Validación Cruzada, Random Forest, XGBoost, LightGBM, optimización de hiperparámetros y técnicas de explicabilidad como SHAP.