

Sumativa 1 — Informe Técnico de Avance del Proyecto

Análisis estadístico de la calidad del aire en Santiago de Chile (red SINCA, 2022-2023)

Asignatura: MCDI501 — Estadística Computacional para la Toma de Decisiones

Programa: Magíster en Ciencias de Datos e Inteligencia Artificial · Universidad Andrés Bello

Fase 2: Búsqueda y recopilación activa de información · RA1 (ID 1.2, 1.3, 1.4)

Integrantes: _____ · **Docente:** _____

Repositorio GitHub: https://github.com/<usuario>/abp_estadistica

1. Introducción y contexto del problema

Santiago de Chile, emplazado en una cuenca rodeada por la cordillera de los Andes, presenta una de las peores calidades de aire de Sudamérica durante el invierno. La geografía favorece fenómenos de **inversión térmica** que atrapan los contaminantes cerca de la superficie, elevando las concentraciones de material particulado **fino (MP2.5)** y **grueso (MP10)**, ambos asociados a enfermedades cardiorrespiratorias. La autoridad ambiental decreta episodios críticos (Alerta, Preemergencia, Emergencia) según umbrales oficiales de norma diaria.

Pregunta movilizadora. ¿Qué evidencia estadística sustenta que la contaminación por material particulado en Santiago presenta diferencias significativas entre zonas geográficas, temporadas y tipos de día, y qué factores meteorológicos y urbanos explican la exposición de la población a episodios críticos?

Objetivo (Fase 2). Aplicar estadística descriptiva e inferencial sobre dos años de mediciones horarias reales de la red SINCA para: (i) caracterizar el comportamiento de los contaminantes, (ii) estimar parámetros poblacionales con intervalos de confianza, y (iii) contrastar hipótesis sobre diferencias espaciales, temporales y de tipo de día que orienten decisiones de política pública bajo incertidumbre.

Tabla 1. Categorías oficiales de calidad del aire (Ministerio del Medio Ambiente).

Calidad del aire	MP10 ($\mu\text{g}/\text{m}^3\text{N}$)	MP2.5 ($\mu\text{g}/\text{m}^3\text{N}$)
Bueno	0 - 149	0 - 50
Regular	150 - 194	51 - 79
Alerta	195 - 239	80 - 109
Preemergencia	240 - 329	110 - 169
Emergencia	≥ 330	≥ 170

2. Conjunto de datos y variables

El estudio utiliza datos **reales de la red SINCA** (Sistema de Información Nacional de Calidad del Aire): **192.720 mediciones horarias** entre el 1 de enero de 2022 y el 31 de diciembre de 2023, provenientes de **11 estaciones** de monitoreo del Gran Santiago. El conjunto se enriqueció con una variable contextual de áreas verdes (INE-SIEDU) y con variables derivadas documentadas. Las variables se clasifican según su tipo estadístico:

Tipo	Variables
Numéricas continuas	mp2_5, mp10, temperatura, humedad, presion, viento, radiacion, isoterma_0, precipitacion
Circular	direccion_viento (0-360°)
Nominales	estacion, comuna, zona_geografica, tipo_dia, estacion_anio, temporada_critica
Ordinales	calidad_aire_mp25, calidad_aire_mp10 (Bueno→Emergencia), nivel_contaminacion (Bajo→Alto)
Binarias	inversion_termica, es_finde, es_festivo, critico_mp25, critico_mp10

Procedencia y trazabilidad. Las variables MP2.5, MP10, temperatura, humedad, presión, viento, radiación, inversión térmica, día de la semana y las marcas de fin de semana/festivo provienen directamente del SINCA. La altura de la isoterma 0 °C, la precipitación y la dirección del viento se derivaron mediante relaciones físicas ancladas a las variables reales (documentado en el script *enriquecer_dataset.py* del repositorio). La superficie de áreas verdes por habitante proviene del INE-SIEDU. Esta distinción se declara por transparencia metodológica.

3. Calidad de datos y metodología

Calidad y limpieza. Se evaluaron tres dimensiones: valores faltantes (~1,5% por columna), duplicados exactos (ninguno en los datos reales) e inconsistencias físicas (humedad > 100%, viento negativo, dirección fuera de 0-360°). Las inconsistencias se convirtieron a valores faltantes (un valor imposible es un error de sensor, no un dato válido) y los faltantes se imputaron por la **mediana de cada estación**, criterio robusto a valores atípicos que respeta la heterogeneidad espacial. Se descartó la eliminación de filas (*listwise deletion*) para no reducir la muestra.

Métodos estadísticos. (1) Estadística descriptiva: medidas de tendencia central, dispersión (incluido el coeficiente de variación), asimetría y curtosis, con histogramas y diagramas de caja. (2) Análisis de frecuencias para variables nominales y ordinales, y tablas de contingencia. (3) Análisis bivariado mediante correlación de Pearson; la dirección del viento se trató como variable circular (descomposición seno/coseno y media circular). (4) Estimación puntual e intervalos de confianza al 95% basados en la distribución *t* de Student. (5) Pruebas de hipótesis: *t* de Welch (varianzas no asumidas iguales, validado con el test de Levene) y χ^2 de independencia, reportando el tamaño del efecto (*d* de Cohen, *V* de Cramér). Nivel de significancia $\alpha = 0,05$ en todas las pruebas. Implementación en Python (pandas, NumPy, SciPy, statsmodels).




Figura 1. Matriz de correlación entre variables numéricas y la inversión térmica.

4. Análisis exploratorio y estadística descriptiva

La media de MP2.5 en el período es de **26,2 $\mu\text{g}/\text{m}^3$** (mediana 24,5; desviación estándar 18,5) y la de MP10 de **54,5 $\mu\text{g}/\text{m}^3$** (desviación 30,3). El elevado **coeficiente de variación** de ambos contaminantes ($\approx 71\%$ en MP2.5) revela una gran dispersión relativa: las concentraciones oscilan fuertemente según la hora, el día y la temporada. La **asimetría positiva** (0,51 en MP2.5) confirma colas largas hacia la derecha —episodios extremos puntuales—, comportamiento típico de variables ambientales que justifica el uso de la mediana en la imputación.




Figura 2. Distribución de MP2.5 y MP10 con la media muestral y el umbral de norma diaria.

En cuanto a las **variables categóricas**, la clasificación oficial de calidad del aire (MP2.5) muestra que la gran mayoría de las horas se ubican en categoría «Bueno» (167.007 horas), seguida de «Regular» (22.265) y «Alerta» (558), sin registros en Preemergencia ni Emergencia en el promedio horario. No obstante, esta lectura agregada oculta una marcada heterogeneidad territorial y estacional que se revela en el análisis bivariado y en las pruebas de hipótesis.




Figura 3. Frecuencias de la categoría de calidad del aire (MP2.5) y del tipo de día.

4.1 Relaciones bivariadas y diferenciadores territoriales

El análisis de correlación (Figura 1) confirma los mecanismos físicos esperados: MP2.5 y MP10 presentan correlación fuerte y positiva (comparten fuentes de combustión y tráfico), mientras que la temperatura, la radiación y el viento correlacionan negativamente con el material particulado —el frío, la baja radiación y la calma atmosférica favorecen la acumulación durante las inversiones térmicas invernales. La **inversión térmica** (variable real del SINCA) muestra una asociación positiva y notable con MP2.5, confirmando el mecanismo central de los episodios críticos de Santiago.




Figura 4. Distribución de MP2.5 por zona geográfica, con el umbral de norma ($50 \mu\text{g}/\text{m}^3$).

La distribución por **zona geográfica** (Figura 4) evidencia una desigualdad territorial marcada: el sector Oriente registra concentraciones sistemáticamente menores que el Poniente y el Sur. Esta brecha se contrasta formalmente en la Sección 6.




Figura 5. MP2.5 según tipo de día: el efecto del tráfico vehicular se aprecia en la mayor mediana de los días laborales.

4.2 Dirección del viento y áreas verdes

La **dirección del viento** es una variable circular: 359° y 1° están casi juntos, por lo que no puede analizarse con la media aritmética ni la correlación de Pearson convencionales. Mediante descomposición en componentes seno/coseno se obtuvo una dirección predominante de **225° (suroeste)** con una concentración direccional $R = 0,79$, coherente con el régimen de vientos de la cuenca de Santiago.




Figura 6. Rosa de los vientos.

Como **variable contextual** se incorporó la superficie de áreas verdes por habitante (INE-SIEDU; estándar oficial: 10 m²/hab). Se observa una tendencia negativa entre áreas verdes y MP2.5, pero la correlación es **moderada y no significativa** ($r \approx -0,49$; $p \approx 0,13$; $n = 11$ comunas). El patrón se rompe en casos como Cerrillos (alta dotación verde pero MP elevado por su ubicación industrial), lo que confirma que las áreas verdes no actúan de forma aislada: están entrelazadas con el nivel socioeconómico y la posición geográfica de la comuna, que determinan otras fuentes de contaminación (leña, parque automotriz, industria). Estos factores actúan como **variables confusoras**; aislar el efecto propio de la vegetación requiere un modelo multivariado (Fase 3). Este hallazgo matizado es, en sí mismo, evidencia del principio *correlación $\neq$ causalidad*.




Figura 7. Áreas verdes por habitante vs. MP2.5 medio por comuna (INE-SIEDU).

5. Estimación de parámetros — intervalos de confianza al 95%

Se estimó la media poblacional de tres variables numéricas relevantes mediante estimación puntual e intervalos de confianza al 95% basados en la distribución *t* de Student. Dado el enorme tamaño muestral, por el Teorema Central del Límite la distribución de la media muestral es aproximadamente normal. Los resultados se resumen en la Tabla 2.

Variable	Media	IC 95% inferior	IC 95% superior	Amplitud
MP2.5 ($\mu\text{g}/\text{m}^3$)	26,17	26,09	26,25	0,16
MP10 ($\mu\text{g}/\text{m}^3$)	54,45	54,32	54,59	0,27
Temperatura ($^{\circ}\text{C}$)	14,00	13,97	14,04	0,07




Figura 8. Intervalos de confianza al 95% para la media de las tres variables.

Interpretación. El intervalo de confianza de MP2.5 [26,09; 26,25] indica que, con un 95% de confianza, la media poblacional de la concentración horaria se sitúa en ese rango. Los intervalos son muy estrechos debido al gran tamaño muestral —la amplitud decrece con la raíz de n —, lo que otorga alta **precisión** a la estimación.

Limitaciones. Un intervalo estrecho refleja precisión en la media, no baja dispersión de la variable (la desviación estándar real sigue siendo alta). Más relevante aún, los registros horarios presentan **autocorrelación temporal** —cada medición se parece a la de la hora anterior—, lo que viola el supuesto de independencia y hace que el intervalo subestime la incertidumbre real. Una corrección rigurosa (errores estándar robustos o remuestreo por bloques) se abordará en la Fase 3.

6. Pruebas de hipótesis

Se realizaron cuatro pruebas de hipótesis (el mínimo exigido es dos), todas con nivel de significancia $\alpha = 0,05$. El test de Levene confirmó heterogeneidad de varianzas, por lo que las comparaciones de medias emplean la **t de Welch**. Se reporta el tamaño del efecto para distinguir significancia estadística de relevancia práctica.

6.1 Prueba 1 — MP2.5 entre zona Oriente y Poniente (t de Welch)

$H_0: \mu(\text{Oriente}) = \mu(\text{Poniente})$; $H_1: \mu(\text{Oriente}) \neq \mu(\text{Poniente})$. Resultado: medias de 16,6 vs. 28,8 $\mu\text{g}/\text{m}^3$; $t = -114$; $p < 0,001$; d de Cohen = 0,72. **Se rechaza H_0** : existe una diferencia estadística y prácticamente relevante (efecto medio-grande) entre ambas zonas.

6.2 Prueba 2 — Diferencia estacional invierno vs. resto del año (t de Welch)

$H_0: \mu(\text{invierno}) = \mu(\text{resto})$; $H_1: \mu(\text{invierno}) > \mu(\text{resto})$. Resultado: 39,6 vs. 19,3 $\mu\text{g}/\text{m}^3$ (105% mayor); $t = 250$; $p < 0,001$; $d = 1,24$. **Se rechaza H_0** : el invierno eleva drásticamente la media de MP2.5, con un tamaño de efecto muy grande.

6.3 Prueba 3 — Tipo de día: laboral vs. fin de semana (t de Welch)

$H_0: \mu(\text{laboral}) = \mu(\text{fin de semana})$; $H_1: \mu(\text{laboral}) > \mu(\text{fin de semana})$. Resultado: 28,0 vs. 22,6 $\mu\text{g}/\text{m}^3$; $t = 62$; $p < 0,001$; $d = 0,31$. **Se rechaza H_0** : los días laborales presentan mayor MP2.5, consistente con el efecto del tráfico vehicular y la actividad productiva.

6.4 Prueba 4 — Independencia entre zona y nivel de contaminación (χ^2)

H_0 : zona y nivel de contaminación son independientes; H_1 : existe asociación. Resultado: $\chi^2 = 8.404$; $gl = 8$; $p < 0,001$; V de Cramér = 0,15. **Se rechaza H_0** : la condición de contaminación no se distribuye al azar entre zonas; la exposición de la población es desigual territorialmente.

Prueba	Estadístico	p-valor	Efecto	Decisión
t Welch — Oriente vs Poniente	$t = -114$	$< 0,001$	$d = 0,72$	Rechaza H_0
t Welch — Invierno vs Resto	$t = 250$	$< 0,001$	$d = 1,24$	Rechaza H_0
t Welch — Laboral vs Finde	$t = 62$	$< 0,001$	$d = 0,31$	Rechaza H_0
χ^2 — Zona vs Nivel contaminación	$\chi^2 = 8.404$	$< 0,001$	$V = 0,15$	Rechaza H_0

Tabla 3. Síntesis de las pruebas de hipótesis. Nota: con muestras grandes casi cualquier diferencia es significativa; el tamaño del efecto indica la relevancia práctica.

7. Interpretación preliminar y conclusiones

La evidencia empírica sobre dos años de datos reales permite extraer cuatro conclusiones preliminares vinculadas al problema de decisión bajo incertidumbre:

1. Desigualdad territorial. El sector Oriente presenta concentraciones de MP2.5 marcadamente menores que el Poniente y el Sur, y el nivel de contaminación se asocia significativamente a la zona (Pruebas 1 y 4). La exposición de la población es desigual, lo que sustenta políticas de **focalización territorial** de las medidas de mitigación con un enfoque de equidad ambiental.

2. Estacionalidad crítica. El invierno duplica la media de MP2.5 respecto del resto del año (Prueba 2), confirmando el efecto de la inversión térmica. Esto justifica los **planes de gestión de episodios críticos** concentrados entre mayo y agosto (restricción vehicular, prohibición del uso de leña).

3. Efecto del tráfico. Los días laborales registran mayor MP2.5 que los fines de semana (Prueba 3), lo que respalda medidas centradas en el **transporte**: restricción vehicular y promoción del transporte público.

4. Áreas verdes como factor contextual. Se observa una tendencia protectora de la vegetación, aunque entrelazada con el nivel socioeconómico (factor confusor), cuyo efecto propio deberá aislarse mediante modelamiento multivariado.

En conjunto, la evidencia respalda decisiones de política diferenciadas por **territorio, temporada y tipo de día**, en lugar de medidas homogéneas para toda la ciudad.

8. Próximos pasos del proyecto (Fases 3-4)

(a) Modelamiento predictivo (RA3). Regresión lineal múltiple para predecir MP2.5 a partir de variables meteorológicas y contextuales, controlando el confusor socioeconómico; regresión logística para la probabilidad de episodio crítico. **(b) Simulación y remuestreo (RA2).** Métodos de Monte Carlo para estimar la frecuencia esperada de episodios bajo distintos escenarios y *block bootstrap* para intervalos que respeten la autocorrelación temporal. **(c) Análisis de sensibilidad** sobre umbrales de norma y decisiones de imputación. **(d) Comunicación (Fase 4):** informe ejecutivo y tablero orientados a la toma de decisiones de política pública ambiental.

Reproducibilidad. El notebook ejecutable (.ipynb), el conjunto de datos y el historial de trabajo se encuentran en el repositorio GitHub enlazado en la portada. El notebook se ejecuta de extremo a extremo sin errores (Kernel → Restart & Run All).

Referencias. Ministerio del Medio Ambiente — SINCA (sinca.mma.gob.cl). INE, MINVU & CNDU — SIEDU (siedu.ine.cl). Centro de Políticas Públicas UC — Mesa de Áreas Verdes. Montgomery & Runger (2018), *Applied Statistics and Probability for Engineers*, Wiley. Virtanen et al. (2020), SciPy 1.0, *Nature Methods*.