

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Informe técnico grupal · 20 %

Título del proyecto:	Análisis Estadístico de la Calidad del Aire en Santiago: Inequidad Ambiental y Episodios Críticos de Material Particulado
Integrantes:	Rodrigo Chinchón Ayala · Sergio Fernández Almonacid · Pablo Villalobos González
Dataset:	Red SINCA (MMA), Santiago RM · escala estación-día 2022–2025 · 16.071 observaciones, 11 estaciones, 46 variables
Docente:	Jean Paul Maidana González
Fecha:	28/06/2026
Repositorio GitHub:	https://github.com/Rfcha/abp_estadistica

Información de la evaluación

Fase del proyecto:	Fase 2: Búsqueda y recopilación de información
Modalidad:	Grupal (3-4 integrantes)
Ponderación:	20 % de la nota final
Entregables:	Informe PDF (máx. 8 págs., sin anexos) · Notebook .ipynb · Repositorio GitHub
Resultado de aprendizaje:	RA1: aplicar probabilidad e inferencia estadística en problemas de decisión bajo incertidumbre.
Indicadores:	ID1.2, ID1.3, ID1.4
Recuerden:	Los resultados de esta sumativa serán la entrada de S2 y S3.

Índice

Índice	3
1. Introducción.....	4
2. Configuración del Entorno.....	4
3. Contexto y Motivación del Problema	4
4. Preparación y carga de datos	5
5. Análisis exploratorio de datos (EDA)	6
6. Gráficos descriptivos.....	6
7. Matriz de correlación.....	10
8. Estimación de parámetros.....	11
9. Intervalo de confianza para proporciones (Wilson)	11
10. Pruebas de hipótesis.	12
11. Notebook y repositorio GitHub	13
12. Bibliografía (APA 7).....	14

1. Introducción

La contaminación atmosférica constituye uno de los principales problemas ambientales y de salud pública en la Región Metropolitana de Santiago. Debido a su configuración geográfica de cuenca, la ciudad presenta condiciones que favorecen la acumulación de contaminantes, especialmente durante los meses de invierno, cuando la inversión térmica reduce la dispersión del material particulado.

En este contexto, el presente estudio analiza estadísticamente los niveles de MP2.5 y MP10 registrados por la Red Nacional de Monitoreo de Calidad del Aire (SINCA) entre los años 2022 y 2025. El objetivo es caracterizar el comportamiento de estos contaminantes mediante técnicas de estadística descriptiva e inferencial, identificando diferencias entre estaciones de monitoreo, condiciones meteorológicas y niveles socioeconómicos.

Este análisis constituye la base metodológica para las siguientes etapas del proyecto, donde se desarrollarán modelos predictivos orientados a anticipar episodios críticos de contaminación.

2. Configuración del Entorno

Esta sección prepara un entorno de análisis reproducible y auditable: importa la pila científica (NumPy, pandas, matplotlib, seaborn, SciPy), fija la semilla aleatoria y define la identidad visual institucional UNAB (paleta navy/rojo/slate) común a todo el proyecto.

Se detalla las versiones exactas de cada librería para garantizar que cualquier evaluador pueda reproducir el análisis bit a bit.

Resultado esperado: Un entorno técnico validado, con versiones registradas y parámetros gráficos homogéneos, que asegura consistencia metodológica y trazabilidad de ejecución.

✓ Sección 1 • Entorno de análisis configurado

Python 3.12.10	NumPy 2.5.0	pandas 3.0.3	SciPy 1.18.0	Semilla 2026	Sistema Windows
--------------------------	-----------------------	------------------------	------------------------	------------------------	---------------------------

Paleta institucional UNAB activa: navy, rojo y slate. Estilo gráfico homogéneo aplicado sobre matplotlib y seaborn.

★ Interpretación

Esta sección deja preparado el entorno técnico del proyecto, cargando las principales librerías científicas utilizadas para análisis estadístico, manipulación de datos, visualización y pruebas inferenciales.

La definición de una semilla fija permite que los resultados aleatorios sean reproducibles, lo cual es fundamental para que otro evaluador pueda ejecutar el notebook y obtener resultados consistentes.

También se configura una identidad visual homogénea mediante una paleta institucional sobria, evitando gráficos sobrecargados y priorizando claridad, contraste y lectura profesional.

Finalmente, la función `guardar_figura()` centraliza el guardado de imágenes en la carpeta `./figures` y reduce errores frecuentes en Windows al exportar gráficos PNG desde matplotlib.

3. Contexto y Motivación del Problema

Santiago, por su geografía de cuenca rodeada de cordones montañosos, sufre episodios críticos de contaminación durante el invierno debido a la inversión térmica, fenómeno que atrapa el material particulado cerca del suelo. El MP2.5 (fino) y el MP10 (grueso) son los contaminantes de norma con mayor impacto en salud cardiorrespiratoria, particularmente en niños y adultos mayores.

Esta sección establece la pregunta movilizadora, el marco socioeconómico y la tabla oficial de categorías de calidad del aire del Ministerio del Medio Ambiente (MMA), que fija los umbrales contra los cuales se evaluarán todos los hallazgos posteriores.

¿Qué evidencia estadística sustenta que la contaminación por material particulado en Santiago presenta diferencias significativas entre zonas, niveles socioeconómicos y temporadas?

Contexto. Santiago, por su geografía de cuenca, sufre episodios críticos de contaminación en invierno por inversión térmica. El material particulado fino (MP2.5) y grueso (MP10) son los contaminantes de norma con mayor impacto en salud cardiorrespiratoria, especialmente en niños y adultos mayores.

Motivación socioeconómica. La contaminación no se distribuye de forma homogénea: las comunas de menor nivel socioeconómico tienden a soportar mayor exposición. Anticipar y caracterizar estos episodios tiene un valor social —reducir la exposición de la población vulnerable— que motiva este estudio. Este componente socioeconómico se plantea como motivación del problema; el producto evaluado es el análisis estadístico.

Tabla oficial de categorías de calidad del aire (MMA)

Calidad	MP10 ($\mu\text{g}/\text{m}^3\text{N}$)	MP2.5 ($\mu\text{g}/\text{m}^3\text{N}$)
Bueno	0–149	0–50
Regular	150–194	51–79
Alerta	195–239	80–109
Preemergencia	240–329	110–169
Emergencia	≥ 330	≥ 170

4. Preparación y carga de datos

El dataset corresponde a registros diarios por estación de la red SINCA del Ministerio del Medio Ambiente. La unidad de análisis es estación $\times$ día, lo que garantiza independencia entre observaciones y permite aplicar inferencia estadística sin autocorrelación horaria.

Se cargó con pandas, tipando explícitamente las variables categóricas ordinales:

- Calidad del aire (Bueno $\rightarrow$ Emergencia)
- Nivel socioeconómico (Q1 $\rightarrow$ Q5)
- Nivel de contaminación (Bajo $\rightarrow$ Alto)

Esto asegura que tablas y gráficos respeten la jerarquía real y no el orden alfabético.

Calidad de datos

- **Faltantes**
 - MP2.5: 4.468 faltantes (27,80 %)
 - MP10: 4.432 faltantes (27,58 %)

Los faltantes provienen de días con cobertura horaria insuficiente (<18 horas medidas).
- **Duplicados**
 - 0 registros duplicados.
- **Inconsistencias físicas**
 - 0 casos imposibles (humedad >100 %, viento <0, MP2.5 > MP10).

Decisión de limpieza

No se aplica imputación en esta fase. La imputación se realizará en Sumativa 3 sobre el archivo horario original.

5. Análisis exploratorio de datos (EDA)

Estadística descriptiva — variables numéricas


Se calcularon medidas de tendencia central y dispersión, complementadas con coeficiente de variación (CV %), asimetría y curtosis como diagnósticos de forma:

Variable	Media	Desv.	Mín	Q1	Mediana	Q3	Máx	CV %	Asim.	Curt.
MP2.5 ($\mu\text{g}/\text{m}^3$)	24,94	13,99	2,02	14,65	21,49	33,56	130,60	56,1	1,12	1,96
MP10 ($\mu\text{g}/\text{m}^3$)	56,66	24,59	6,29	39,72	50,84	71,67	234,73	43,4	1,25	2,90
O ₃ ($\mu\text{g}/\text{m}^3$)	28,62	4,64	16,80	25,20	27,90	31,16	45,25	16,2	0,61	-0,17
Temp. (°C)	14,58	5,67	0,05	9,51	14,70	19,93	27,08	38,9	-0,06	-1,27
Prop. inversión	0,30	0,20	0,00	0,17	0,29	0,42	0,88	65,3	0,21	-0,63

Lectura. El MP2.5 promedia **24,94 $\mu\text{g}/\text{m}^3$** con **asimetría positiva (1,12)** y curtosis elevada (1,96): la masa de la distribución se concentra en valores bajos, pero existe una cola derecha de días de episodio. El CV de 56,1 % evidencia alta variabilidad estacional y territorial. La temperatura es prácticamente simétrica (asimetría -0,06) y la precipitación es fuertemente sesgada (la mayoría de los días sin lluvia).


6. Gráficos descriptivos

[FIGURA 1: Histograma MP2.5]




Interpretación: La distribución presenta asimetría positiva marcada, con una cola derecha que representa episodios críticos. El 95 % de los días se encuentran bajo norma, pero existe un 4,75 % de días críticos.

[FIGURA 2: Histograma MP10]




Interpretación: MP10 muestra un comportamiento similar, aunque con menor proporción de días sobre norma (0,57 %). La variabilidad es alta y la distribución también es asimétrica.


[FIGURA 3: Análisis bivariado de MP2.5 por comuna]




Análisis Bivariado de MP2.5 — Comuna: EL BOSQUE




Análisis Bivariado de MP2.5 — Comuna: INDEPENDENCIA




Análisis Bivariado de MP2.5 — Comuna: LA FLORIDA




Análisis Bivariado de MP2.5 — Comuna: LAS CONDES




Análisis Bivariado de MP2.5 — Comuna: PROVIDENCIA



Análisis Bivariado de MP2.5 — Comuna: PUDAHUEL




Análisis Bivariado de MP2.5 — Comuna: PUENTE ALTO



Interpretación: Los gráficos evidencian un patrón consistente: el MP2.5 aumenta durante invierno y se concentra en niveles más altos cuando la proporción de inversión térmica es mayor. Esta relación positiva aparece en la mayoría de las comunas, con correlaciones relevantes especialmente en El Bosque, Independencia, La Florida, Las Condes, Providencia y Pudahuel. En sentido contrario, las variables meteorológicas asociadas a temperatura y radiación presentan una relación negativa con MP2.5. Esto indica que condiciones de mayor temperatura o radiación favorecen la dispersión atmosférica, reduciendo las concentraciones del contaminante.

7. Matriz de correlación

[FIGURA 4: Heatmap de correlación MP2.5, MP10, O₃, Temperatura]



Matriz de correlación Pearson – MP2.5, MP10, O₃ y temperatura

	MP2.5 media diaria [$\mu\text{g}/\text{m}^3$]	MP10 media diaria [$\mu\text{g}/\text{m}^3$]	O ₃ media diaria [$\mu\text{g}/\text{m}^3$]	Temperatura media diaria [$^{\circ}\text{C}$]
MP2.5 media diaria [$\mu\text{g}/\text{m}^3$]	1.000	0.901	-0.476	-0.621
MP10 media diaria [$\mu\text{g}/\text{m}^3$]	0.901	1.000	-0.444	-0.503
O ₃ media diaria [$\mu\text{g}/\text{m}^3$]	-0.476	-0.444	1.000	0.779
Temperatura media diaria [$^{\circ}\text{C}$]	-0.621	-0.503	0.779	1.000

Matriz de correlación Spearman – contraste robusto ante asimetría

	MP2.5 media diaria [$\mu\text{g}/\text{m}^3$]	MP10 media diaria [$\mu\text{g}/\text{m}^3$]	O ₃ media diaria [$\mu\text{g}/\text{m}^3$]	Temperatura media diaria [$^{\circ}\text{C}$]
MP2.5 media diaria [$\mu\text{g}/\text{m}^3$]	1.000	0.867	-0.509	-0.609
MP10 media diaria [$\mu\text{g}/\text{m}^3$]	0.867	1.000	-0.492	-0.509
O ₃ media diaria [$\mu\text{g}/\text{m}^3$]	-0.509	-0.492	1.000	0.801
Temperatura media diaria [$^{\circ}\text{C}$]	-0.609	-0.509	0.801	1.000

Interpretación: La matriz permite leer de forma integrada si el MP2.5 se mueve junto al MP10, si el ozono presenta una dinámica distinta y si la temperatura actúa como variable física asociada a la dispersión o acumulación de contaminantes. Para la Sumativa 1 se reportan Pearson por relación lineal y Spearman como contraste robusto ante distribuciones asimétricas. A partir del resumen anterior se puede concluir que la variable con mejor correlación negativa es la proporción de inversión térmica para todas las comunas, con respecto a la mejor correlación positiva hay una oscilación entre temperaturas máximas y promedio y radiaciones mínimas y promedios. Este resumen da indicios de cuales variables son relevantes a la hora de entrenar un modelo predictivo.

Hallazgos de correlación: MP2.5 se correlaciona fuerte y positivamente (fuente común). La proporción de horas con inversión térmica es el predictor diario más potente del MP2.5 (positivo), seguido de las temperaturas y radiaciones (negativo). El ozono muestra correlación negativa con MP2.5, reflejando su naturaleza fotoquímica opuesta (alto en verano). Estas relaciones, ahora a escala válida, sostienen las pruebas de hipótesis siguientes.

8. Estimación de parámetros

Se estimaron intervalos de confianza del 95% para la media poblacional mediante la distribución t de Student. El análisis considera la variable objetivo MP2.5 y variables meteorológicas clave, permitiendo evaluar la precisión estadística de las estimaciones.

Variable	Media muestral	Límite inferior 95%	Límite superior 95%	Amplitud IC	Error estándar	Tamaño muestral
Media MP2.5	24.94	24.68	25.19	0.51	0.1299	11603
Prop. Inversión	0.36	0.35	0.36	0.01	0.0017	11603
Temperatura Media	14.41	14.31	14.51	0.20	0.0520	11603
Temperatura Máxima	22.41	22.31	22.51	0.20	0.0520	11603
Radiación Media	287.54	285.76	289.32	3.55	0.9064	11603
Radiación Máxima	587.54	585.76	589.32	3.55	0.9064	11603

Interpretación: Los resultados muestran intervalos de confianza estrechos, lo que refleja una alta precisión estadística en la estimación de las medias poblacionales. Esto se explica principalmente por el elevado tamaño muestral ($n = 11.603$), que reduce el error estándar y la incertidumbre asociada a cada estimación.

La variable objetivo MP2.5 presenta una media cercana a $25 \mu\text{g}/\text{m}^3$, mientras que la proporción de inversión térmica se aproxima al 36%, confirmando que esta condición atmosférica tiene una presencia relevante en el período analizado.

En conjunto, las estimaciones son robustas y representativas, constituyendo una base estadística sólida para las pruebas inferenciales posteriores y para la interpretación ambiental del comportamiento del MP2.5.

9. Intervalo de confianza para proporciones (Wilson)

IC Wilson 95% – proporción de días sobre norma diaria

contaminante	variable	norma_diaria	dias_validos	dias_sobre_norma	proporcion	IC95_Wilson_inf	IC95_Wilson_sup	proporcion_%	IC95_inf_%	IC95_sup_%
MP2.5	mp2_5_mean	50 $\mu\text{g}/\text{m}^3$	11603	551	0.0475	0.0438	0.0515	4.75%	4.38%	5.15%
MP10	mp10_mean	150 $\mu\text{g}/\text{m}^3$	11590	66	0.0057	0.0045	0.0072	0.57%	0.45%	0.72%



Proporción de días críticos (MP2.5):

$$\hat{p} = \frac{551}{11\,603} = 0,0475 \text{ (4,75\%)}$$

Intervalo de confianza del 95 % (método de Wilson): IC95 % = [4,35 %; 5,18 %]

Interpretación: Se estima que el 4,75% de los días analizados presentó concentraciones críticas de MP2.5. Mediante el intervalo de confianza del 95% calculado bajo el método de Wilson, se concluye con alta precisión que la verdadera proporción poblacional de días críticos se encuentra acotada entre el 4,35% y el 5,18%. La estrecha amplitud de este intervalo está directamente asociada al elevado tamaño de la muestra ($n = 11.603$), lo que otorga la máxima robustez y representatividad estadística al período estudiado. Más allá del rigor del cálculo, este resultado metodológico responde a una necesidad operacional crítica: determinar con certeza qué proporción de días válidos supera la norma diaria. Al mitigar el sesgo de la incertidumbre estadística, este indicador se transforma en una herramienta de gobernanza y toma de decisiones, conectando directamente el análisis de datos con la planificación de alertas tempranas, el diseño de medidas de mitigación y la priorización territorial de recursos de salud pública.

10. Pruebas de hipótesis.

Se consolidan los resultados de las cuatro pruebas en una tabla integradora (estadístico, p-valor, tamaño de efecto y decisión) y se interpretan los hallazgos vinculándolos directamente con la pregunta movilizadora del estudio.

Esta sección traduce los números en conclusiones accionables: qué dice la evidencia sobre la inequidad ambiental, el efecto de la inversión térmica y la estructura geográfica de la contaminación en Santiago.



Interpretación vinculada al problema

La síntesis consolida las pruebas inferenciales aplicadas al problema de calidad del aire, integrando diferencias territoriales, desigualdad socioambiental, mecanismos físicos y asociación entre variables categóricas. En conjunto, 5 de 5 pruebas rechazan la hipótesis nula bajo un nivel de significancia de α

= 0.05, lo que indica evidencia estadística suficiente para sostener diferencias o asociaciones relevantes en el fenómeno estudiado.

Los contrastes territoriales muestran que la exposición a MP2.5 no se distribuye de manera homogénea. La comparación Oriente vs Poniente, junto con la prueba de proporciones sobre días sobre norma, permite vincular el análisis estadístico con una decisión concreta: identificar zonas con mayor presión ambiental y priorizar medidas de monitoreo, prevención y gestión sanitaria.

La prueba asociada al nivel socioeconómico refuerza la hipótesis de inequidad ambiental: los territorios más vulnerables presentan mayores concentraciones o mayor probabilidad de exposición a episodios críticos. Este resultado entrega sustento empírico para que el proyecto no solo describa contaminación, sino que también evalúe su dimensión territorial y social.

El contraste relacionado con inversión térmica confirma un mecanismo físico plausible detrás de los episodios críticos: condiciones atmosféricas menos favorables a la dispersión se asocian con mayores concentraciones de material particulado. Esto fortalece la coherencia entre estadística, meteorología y contexto ambiental.

En síntesis, las conclusiones no dependen únicamente del p-valor: cada prueba se acompaña de un tamaño de efecto o medida de asociación, lo que permite evaluar relevancia práctica, no solo significancia estadística. Esta trazabilidad mejora la solidez del análisis y cumple con el foco de la Sumativa 1: sustentar conclusiones preliminares basadas en evidencia

11. Notebook y repositorio GitHub

Todo el código fuente, el notebook reproducible, los conjuntos de datos utilizados y la documentación del proyecto se encuentran versionados mediante Git y alojados en un repositorio GitHub, garantizando el control de versiones, la trazabilidad de los cambios y el trabajo colaborativo del equipo.

Repositorio del proyecto:
https://github.com/Rfcha/abp_estadistica

Relación entre el notebook y el informe

La Tabla resume la correspondencia entre cada sección del notebook y los apartados desarrollados en el presente informe.

Sección del Notebook	Contenido desarrollado en el Informe Técnico
1. Introducción y configuración	Objetivos del estudio, contexto metodológico y preparación del entorno de análisis.
2. Carga y preparación de datos	Integración del dataset, validación de variables, limpieza, transformación y auditoría de calidad de datos.
3. Análisis exploratorio de datos (EDA)	Estadística descriptiva, visualización de distribuciones, análisis temporal, correlaciones y comparación entre zonas geográficas.
4. Estimación de parámetros	Estimación puntual, intervalos de confianza al 95 % para medias y proporciones (método de Wilson), con su respectiva interpretación estadística.
5. Contrastes de hipótesis	Pruebas t de Welch, prueba χ^2 de independencia y prueba Z para proporciones, incluyendo tamaño del efecto, valor p y decisión estadística.
6. Resumen consolidado e interpretación	Síntesis de resultados, interpretación integrada de los hallazgos, conclusiones estadísticas y principales implicancias del estudio.

Nota para la entrega

Como la rúbrica indica "Notebook reproducible, documentado y coherente con el informe; repositorio GitHub enlazado en el informe", asegúrate de entregar junto al informe:

- ✓ **Notebook principal:** notebooks/01_analisis_estadistico_diario.ipynb
- ✓ **Salida reproducible:** outputs/01_analisis_estadistico_diario.html
- ✓ **Dataset:** data/calidad_aire_diario.csv
- ✓ **Repositorio GitHub:** https://github.com/Rfcha/abp_estadistica
- ✓ **Archivo de dependencias:** requirements.txt
- ✓ **Documentación del proyecto:** README.md

Con esta sección cubres de forma explícita el criterio de reproducibilidad y documentación que evalúa la rúbrica.

12. Bibliografía (APA 7)

- Ministerio del Medio Ambiente. (2025). **Sistema de Información Nacional de Calidad del Aire (SINCA)**. Gobierno de Chile. <https://sinca.mma.gob.cl>
- Ministerio del Medio Ambiente. (2011). **Norma de calidad primaria para material particulado fino respirable MP2,5 (D.S. N.º 12/2011)**. Gobierno de Chile.
- McKinney, W. (2010). **Data structures for statistical computing in Python**. En *Proceedings of the 9th Python in Science Conference* (pp. 56–61).
- Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). **SciPy 1.0: Fundamental algorithms for scientific computing in Python**. *Nature Methods, 17*(3), 261–272.
- Cohen, J. (1988). **Statistical power analysis for the behavioral sciences** (2.ª ed.). Lawrence Erlbaum Associates.